

论文复现报告

论文复现报告

论文: Liang & Jia (2022) *China futures price forecasting based on online search and information transfer*
目标: 忠实复现论文完整流程 (搜索数据 → ICPI → 传递熵 TE → GWO-CNN-LSTM 预测) 日期: 2026-08-15

一、做了什么 (完整流程)

按论文章节顺序, 用三个脚本忠实复现:

步骤	脚本	论文对应	做了什么
1. 特征构建	<code>reproduce_features.py</code>	\$2.2 + \$3.1	9 关键词 → 对数 → 时滞平移 → z-score → PCA(特征值>1) → Eq(4)加权 → ICPI
2. 传递熵	<code>reproduce_te.py</code>	\$3.2 + \$4.2	KSG 估计器, 窗口 60 / 步长 1, 双向 + 净流
3. 预测模型	<code>reproduce_model.py</code>	\$3.3 + \$3.4	GWO 优化 6 超参 → CNN-LSTM, 对比 [仅价格] vs [价格 + ICPI + TE]

数据: 百度指数 (中文, `data/baidu_index/`) + 谷歌趋势 (英文, `data/google_trends/`) + 5 个期货品种 (玉米 C0、大豆 A0、PVC V0、鸡蛋 JD0、螺纹钢 RB0), 区间 2016-04-01 ~ 2021-04-30。

二、关键技术决策 (对齐论文)

- 9 个关键词的精确映射 (论文 Table 4), 调整天数已逐字核对:
 - 谷歌(英文): `decrease in price` (-3)、`price decrease` (-2)、`price rise` (0)、`price` (-8)
 - 百度(中文): `价` (0)、`上涨` (0)、`下跌` (-7)、`涨价` (-4)、组合项 $(1+\text{涨价})/(1+\text{降价})$ (-4)
- 组合项: 用 Antweiler & Frank (2004) 式(2) $\text{pos} = (1+\text{涨价})/(1+\text{降价})$ 合并正负情绪词。
- 标准化方式反推: 论文未明说, 但从 Table 6 的 9 个特征值总和 = 9 (每个词方差=1) 反推出论文做了 **z-score 标准化** (不是 min-max)。

4. 谷歌趋势跨段重标定（本次最关键修复，见下节）。

三、遇到并解决的关键问题

问题 1：谷歌趋势分段“人工跳变”（影响 ICPI 质量）

Google Trends 单次请求只返回 ≤ 270 天日度数据，且**每段各自归一化到 0–100（以本段峰值为 100）**。若直接按不重叠分块拼接，每段的“100”代表不同的绝对搜索量，段边界会出现 0–100 量级的人工跳变，污染后续的对数/标准化/PCA/传递熵。

修复：采用论文引用的 Xu et al. (2019) 的**重叠锚点重标定**——分块时相邻段重叠 60 天，在重叠区用两段比例算缩放因子，把后一段拉到前一段（已锚定）的尺度上再拼接。

效果：段边界跳变从 0–100 量级降到 0–15；ICPI 方差贡献率从 **63.69%** $\rightarrow$ **68.33%**（更接近论文的 79.01%）。

问题 2：梯子（VPN）不生效导致谷歌抓取超时

之前一直连不上 `trends.google.com`。诊断发现：你的梯子**是系统代理模式**，端口 **127.0.0.1:4088**（非常规端口），而 Python 的 `requests / pytrends` **默认不读 Windows 系统代理**，所以直连超时。

修复：从注册表自动读取系统代理，显式传入 `pytrends`。现在 `fetch_google_trends.py` 会自动检测代理，端口变了也不怕。

问题 3：抓取脚本死循环

`chunk_ranges` 里当游标走到末尾 `e-overlap` 后，`t = min(cur+240, e) = e` 恒成立、`cur = e-60` 不再前进，导致无限 `append` 直至内存耗尽（`MemoryError`）。已加 `if t >= e: break`。

四、结果

4.1 ICPI（第一步产物）

- 主成分数：**3 个**（论文 4 个）
- 累计方差贡献率：**68.33%**（论文 79.01%）
- 各主成分特征值：3.518 / 1.457 / 1.174（论文 4 个主成分）
- Eq(4) 权重：0.572 / 0.237 / 0.191（论文 0.434 / 0.228 / 0.194 / 0.144）

4.1.1 ICPI 差距溯源（本次排查）

结论：关键词映射与预处理顺序全部正确，差距出在数据本身——谷歌趋势的 4 个英文词太“同质”，塌缩成 1 个因子，把第 4 个主成分挤没了。

完整特征值谱对比（z-score 后总方差=9）：

主成分	我们特征值	贡献率	论文特征值	论文贡献率
PC1	3.518	39.09%	3.085	34.28%
PC2	1.457	16.19%	1.622	18.02%
PC3	1.174	13.05%	1.378	15.31%
PC4	0.736	8.18%	1.027	11.41%

我们的谱整体更“集中”：PC1 大 0.43、PC4 小 0.29，第 4 个主成分从论文的 1.027（刚过 1）掉到 0.736（刚不过 1）。这就是 3 vs 4 个主成分、68.33% vs 79.01% 的全部来源。

子块分解精确定位：

数据块	特征值谱	有效因子数	平均 r
GT 英文 4 词	2.274 / 0.801 / 0.605 / 0.321	1 个	0.420
BDI 中文 5 词	2.358 / 1.176 / 0.724 / ...	2 个	0.333

BDI 块健康贡献 2 个因子；GT 块只贡献 1 个——因为 decrease in price / price decrease 是同词换序（相关 0.663）、price rise / price 也是近义，它们齐涨齐跌，本质是一个信号。论文那边 4 个英文词有更独立的波动（贡献 2 因子），于是 2(GT)+2(BDI)=4 个主成分。

根因（不可复现的数据层差异）：论文抓的是 2021 年时点的 Google Trends “adjusted” 数据，我们是 2026 年抓的；GT 会回溯性重调历史数值，同一时段不同抓取时点拿到的相对搜索强度不同，英文近义词这种高相关词群最敏感。且论文未写明 geo 与抓取时点，Xu et al. (2019b) 日度重建也仅是近似。百度中文词相对稳定（BDI 块符合预期），故问题几乎可锁定在谷歌英文词上。

4.2 传递熵 TE（第二步产物）

品种	净流均值	net>0 占比
玉米 C0	-0.0009	50.0%
大豆 A0	-0.0018	48.3%
PVC V0	-0.0217	36.7%
鸡蛋 JD0	-0.0277	33.4%
螺纹钢 RB0	-0.0034	48.6%

4.3 预测模型（第三步）

对比 [仅价格] vs [价格+ICPI+TE]，评价 MAE/RMSE/MAPE/R²（R² 越高越好，其余越低越好）：

品种	输入特征	MAE	RMSE	MAPE	R²	融合改善(MAE)
玉米 C0	仅价格	66.25	80.64	2.56%	0.876	—
玉米 C0	价格+ICPI+TE	87.20	104.49	3.35%	0.836	-31.6%
大豆 A0	仅价格	125.54	160.78	2.32%	0.920	—
大豆 A0	价格+ICPI+TE	322.93	411.86	5.91%	0.432	-157.2%
PVC V0	仅价格	163.01	253.68	2.07%	0.925	—
PVC V0	价格+ICPI+TE	167.24	249.36	2.12%	0.914	-2.6%
鸡蛋 JD0	仅价格	84.60	124.10	2.29%	0.942	—
鸡蛋 JD0	价格+ICPI+TE	78.41	120.36	2.03%	0.939	+7.3% 
螺纹钢 RB0	仅价格	72.84	110.91	1.66%	0.946	—
螺纹钢 RB0	价格+ICPI+TE	82.35	110.65	1.89%	0.936	-13.1%

结论：5 个品种中 4 个融合模型比纯价格更差，仅鸡蛋 JD0 有 7.3% 的小幅改善。论文“加入 ICPI+TE 提升预测精度”的结论未复现。

补充：玉米用论文原参数（500 epochs / 重复 10 次）再验

品种	输入特征	MAE	RMSE	MAPE	R²	融合改善(MAE)
玉米 C0	仅价格	72.86	88.37	2.79%	0.862	—
玉米 C0	价格+ICPI+TE	99.22	119.58	3.79%	0.769	-36.2%

改用论文原参数后结论不变：融合模型仍更差（-36.2%），且纯价格模型的 R² 反而从 0.876 降到 0.862（500 epochs 在训练集上过拟合）。

消融实验：定位是哪个特征在拖后腿（玉米 C0，500 epochs/10 次）

输入特征	MAE	RMSE	MAPE	R²
仅价格（基线）	72.86	88.37	2.79%	0.862

输入特征	MAE	RMSE	MAPE	R ²
价格 + ICPI	125.03	151.49	4.76%	0.663
价格 + TE	69.25	84.71	2.69%	0.873 ✓
价格 + ICPI + TE	99.22	119.58	3.79%	0.769

结论：拖累融合模型的是 ICPI，不是 TE。 - **TE 单独加入反而有益**：R² 从 0.862 升到 0.873（全场最佳），MAE 也最低——说明“搜索→价格”的传递熵确实携带有用信息。 - **ICPI 单独加入大幅拖累**：R² 从 0.862 掉到 0.663，MAE 几乎翻倍——说明我们构建的 ICPI 对玉米价格没有预测价值，甚至是噪声。 - **两者合用时，ICPI 的负面影响淹没了 TE 的正面作用**（0.769）。

这与 ICPI 方差贡献率偏低（68.33% vs 论文 79.01%）、以及各品种 TE 净流微弱并不矛盾——TE 本身仍有一点点信息，但 ICPI 这个“互联网物价指数”在玉米品种上没能起到论文声称的作用。

对齐论文数据期后的复现（玉米，数据截至 2020-09-30）

发现论文 Table 1 玉米统计量（最大 2460 / 最小 1392 / 均值 1798.7 / 标准差 189）与我们数据**截至 2020-09-30** 几乎完全吻合（我们 2484 / 1389 / 1798.6 / 206），说明论文玉米数据实际止于 2020 年 9 月底左右（而非论文声称的 2021 年 4 月，2021 年玉米大涨到 2877 不在论文数据里）。论文用的是**开盘价**（全文 6 处 “opening price”、0 处 “closing price”），与我们用的 open 列一致。

把价格+搜索数据统一截至 2020-09-30 重跑（ICPI 主成分 3 个、方差 62.57%）：

玉米	我们(截断) MAE	我们 R ²	论文 MAE	论文 R ²
仅价格	34.04	0.893	21.09	0.747
价格+ICPI+TE	75.10	0.473	15.25	0.831

结论：1. **仅价格模型基本对上**——截断后 MAE 从 72.86 降到 34.04（离论文 21.09 近多了，1.6 倍 vs 原来 3.5 倍），R² 甚至高于论文（0.893 vs 0.747）。说明之前的 MAE 量级差很大部分是 2021 年大涨段造成。2. **融合模型仍无法复现，且更差**——数据期对上后 R² 反而 0.893→0.473（论文是 0.747→0.831）。根因是 **ICPI 质量**：我们 ICPI 只有 3 个主成分 / 62.57% 方差，论文 4 个 / 79.01%。ICPI 信息量不足是复现失败的主因，与数据期无关。

五、诚实结论

- 1. **流程忠实复现成功**：9 关键词 → 对数 → 时滞 → z-score → PCA → ICPI → TE → GWO-CNN-LSTM 每一步都与论文对齐，关键参数（Table 4 调整天数、特征值>1、Eq(4) 权重公式、KSG 传递熵、GWO 6 超参）均已实现。
- 2. **ICPI 与论文有差距（68.33% vs 79.01%）是数据层面的诚实结果**，最可能的原因是：

- 论文用的谷歌趋势原始数据（抓取时点、地域 geo、是否含更多关键词）我们无法完全还原；
- 论文可能对谷歌数据做了额外平滑或用了不同时间窗。
- 主成分 3 vs 4 个的差异，直接导致累计方差低约 10 个百分点。

3. **谷歌趋势重标定是必要的且有效**：不做会人为制造断点，做了后 ICPI 质量明显改善。

4. **模型结果的含义**：论文结论是“加入 ICPI + TE 能提升预测精度”，但我们的忠实复现得到**相反结果**——5 个品种里 4 个融合模型比纯价格更差（玉米 -31.6%、大豆 -157.2%、PVC -2.6%、螺纹钢 -13.1%），仅鸡蛋 +7.3% 小幅改善。可能原因（供老师交流/答辩参考）：

- **ICPI 信息量不足**：我们的 ICPI 只有 3 个主成分、68.33% 方差（论文 4 个、79.01%），信息浓缩程度偏低；
- **传递熵净流微弱**：各品种 TE 净流均值接近 0（见 §4.2），说明“搜索→价格”的因果信息流很弱，TE 特征基本是噪声；
- **小模型对噪声敏感**：CNN-LSTM 会主动混合全部输入特征，加入无信息量的 ICPI/TE 反而干扰学习；
- **数据/训练随机性**：论文的谷歌数据抓取时点、地域、训练随机种子我们无法完全还原。这是**诚实且可辩护**的复现结果——复现的意义在于检验结论的可复现性，而非强求一致。

六、如何重跑

```
# 需先开梯子（系统代理），脚本会自动读代理
python fetch_google_trends.py           # 抓谷歌数据（含跨段重标定）
python reproduce_features.py             # 构建 ICPI + 品种特征
python reproduce_te.py                   # 计算传递熵
python reproduce_model.py                 # GWO-CNN-LSTM（全部5品种）
python reproduce_model.py C0              # 只跑玉米
```

注：运行 torch 的脚本前加 `KMP_DUPLICATE_LIB_OK=TRUE`（Windows 上 numpy/MKL 与 torch 的 libiomp5md.dll 冲突）。