

论文1阅读总结

论文1 阅读总结

标题: Text-based soybean futures price forecasting: A two-stage deep learning approach **作者:** Wuyue An、Lin Wang (华中科技大学管理学院)、Yu-Rong Zeng (湖北经济学院信息工程学院) **期刊:** Journal of Forecasting, 2023, 42(2): 312–330. DOI: 10.1002/for.2909 **数据可得性:** 可向通讯作者合理索取 (zyrhbue@gmail.com)

一、一句话概括

用**微博文本** (做情感分析 + 涨跌分类) 提取 3 个文本特征, 结合 10 个经济变量, 用**逐步回归**筛选因子, 最后用**两阶段 LSTM (TSH-LSTM)** 预测中国大豆期货价格, 证明“文本特征确实能提升预测精度”。

二、研究问题与动机

- 传统大豆期货预测只依赖**历史价格/宏观数据**, 忽略了社交媒体情绪等外部因素;
- 现有情感分析**没考虑领域情感词** (很多词在期货语境下含义不同), 也**只挖到文本表层特征** (情感), 没挖到深层特征 (涨跌);
- 本文用“情感词典 + 社会网络分析”改进情感分析, 用 textRCNN 挖涨跌深层特征。

三、整体框架 (四阶段)

阶段1	数据采集与预处理	数值数据(10) + 微博文本 → 清洗/编码/归一化
阶段2	文本特征挖掘	CDCSA情感分析 → 情感分 textRCNN涨跌分类 → 涨跌标签
阶段3	逐步回归筛选	13个候选因子 → 显著因子 (SPSS)
阶段4	TSH-LSTM预测	单变量LSTM + 多变量LSTM → 误差倒数法融合

四、数据集详解

4.1 数值数据（10 个变量）

时间：2011-07-29 ~ 2021-07-19，有效 795 天。来源：国家统计局、全国农产品成本收益资料汇编、世界银行 + 交易所行情。

类别	变量	中文	主要来源
期货市场	X1 持仓量	大豆期货持仓	交易所
期货市场	X2 成交量	大豆期货成交	交易所
期货市场	X4 美豆期货价	CBOT美豆	世界银行/Wind
大豆基本面	X3 大豆现货价	现货价	国家统计局
大豆基本面	X7 黄玉米期货收盘价	玉米C0	交易所
大豆基本面	X8 黄玉米持仓量	玉米持仓	交易所
大豆基本面	X9 食用油现货指数	食用油指数	国家统计局
经济环境	X5 汇率	美元/人民币	世界银行/央行
经济环境	X6 WTI原油现货价	WTI现货	世界银行/EIA
经济环境	X10 WTI原油期货价	WTI期货	EIA

依赖变量 Y = 大豆期货**收盘价**（注意：论文2用开盘价，论文1用收盘价）。训练/测试划分：前 85% 训练、后 15% 测试；训练集里再分 15% 作验证集。


4.2 文本数据（微博 + 粮油网站）

- 来源：微博上关于大豆期货的帖子 + “China Food”（粮油类网站）相关信息；
- 采集：Python 3.7 网络爬虫，2011–2021 共约 10 年；
- 最终产出 3 个文本特征：Sentimenttrend（词典情感分）、Im sentimenttrend（CDCSA改进情感分）、Labeltrend（涨跌标签）。

五、文本数据处理详解（核心，重点看这里）

文本是**非结构化的**（一句话、一段字），模型算不了。所以要分**两条路**把它变成**数字**：

微博文本（“大豆今天大涨了！”）



5.1 路1: CDCSA 情感分析（改进情感分怎么算）

CDCSA = 情感词典法 + 社会网络分析的度中心性 + 并列/转折约束。分三步：

第1步：建“领域情感词典” 把两个通用词典合并，并补充网络新词：- **清华李军褒贬义词典**（通用正/负情感词）- **知网 HowNet 情感词典**（通用正/负情感词）- 用 **PMI（点互信息）** 识别并判定网络新词的情感倾向（比如“起飞”“割韭菜”这类词典里没有、但网上常用的词）

为什么要“领域”词典？因为通用词典分不清期货语境——比如“暴跌”在通用词典是中性，但在期货语境是明确的负面词。

第2步：算“度中心性”，并识别并列/转折关系 - **度中心性**：把情感词当节点，两个词若在同一条微博里共现就连一条边，构成一个词网络。某词的度中心性 = 它连了几个词 / (总词数-1)。连得越多，说明这个词越“核心”、情感倾向越强（式1）。- **并列关系**（“大涨和利好”）：两个词情感倾向相同，互相加强；- **转折关系**（“涨了但是回落”）：两个词情感倾向相反，要反转。

第3步：加权求和得到每天的情感分 把当天所有微博里的情感词按“极性 × 度中心性”，再用并列/转折关系修正正负号，累加 → 得到当天整体情感分。

结果：CDCSA 的 Accuracy/Precision/Recall/F1 = **0.8 / 0.83 / 0.81 / 0.82**，比纯词典法（0.68）高，说明“度中心性 + 并列转折”确实有用。

5.2 路2: textRCNN 涨跌分类（深层特征怎么挖）

目标是：**判断“某条微博的内容是在说涨还是跌”**。做法是给它打标签再训练分类器。

打标签（式5）：用价格自己定义对错——- 当天价 > 昨天价 → 标签 +1（涨）- 当天价 < 昨天价 → 标签 -1（跌）

textRCNN 模型（“文本循环卷积神经网络”）：1. **Word2vec 词嵌入**：把每个词变成一个向量（把“大涨”变成一串数字）；2. **BiLSTM**：从正反两个方向读句子，学上下文（“涨”前面是“不”还是“大”，意思完全不同）；3. **拼接**：每个词的左上下文 + 词本身 + 右上下文 拼成一个向量（式2-4）；4. **Max pooling**：从所有词向量里取最强的特征；5. **Softmax 分类**：输出“涨/跌”。

对比了 Transformer、TextCNN、DPCNN、TextRNN_Att 等模型，**textRCNN 10 折交叉验证准确率最高 (62.5%)**。

所以 X13 Labeltrend 就是“每天被判定为涨的微博比例/倾向”，它反映了**文本里隐含的涨跌信号**。

5.3 三个文本特征小结

特征	含义	怎么来的
X11 Sentimenttrend	词典法情感分	清华+HowNet 词典，正负词数比
X12 lmsentimenttrend	CDCSA 改进情感分	词典 + 度中心性 + 并列转折
X13 Labeltrend	涨跌标签特征	textRCNN 分类 (Word2vec+BiLSTM)

六、特征筛选：逐步回归 (SPSS)

把 13 个候选因子 (10 数值 + 3 文本) 做**逐步回归**：逐个引入，F 检验/t 检验显著的留下，不显著的剔除。

结果：最终模型 **只剔除了 X9 (食用油现货指数)**，其余 12 个全保留，**调整 $R^2 = 0.922$** 。说明这 12 个因子 (含 3 个文本特征) 对大豆期货价格解释力很强。

七、预测模型：TSH-LSTM (两阶段)

阶段A 单变量 LSTM：只输入历史价格 → 预测 $S(t)$ （短期准，长期差）

阶段B 多变量 LSTM：输入筛选后的12个因子 → 预测 $M(t)$ （长期稳）

↓ 误差倒数法加权融合

最终预测 = $w1 \cdot S(t) + w2 \cdot M(t)$ （误差小的权重更大）

- 最优序列长度 **Seq_length = 7** (约一周) ；
- 环境：Anaconda + Python 3.7 + PyTorch 1.13.1;
- 超参用网格搜索。

八、结果

模型	MAPE	RMSE	MAE
TSH-LSTM	5.891%	0.094	0.068
单变量 LSTM	8.716%	0.102	0.084
多变量 LSTM	26.531%	0.217	0.182
XGBoost	59.862%	0.314	0.276

TSH-LSTM 全面最优，证明“ 文本特征 + 两阶段融合” 有效。

九、创新点

1. **CDCSA 情感分析方法**：把“ 度中心性（社会网络分析） “引入情感词典法，并识别**并列/转折**关系，弥补了通用词典在期货领域不准的缺陷（准确率 0.68→0.8）；
2. **textRCNN 挖深层涨跌特征**：不只做表层情感，还用“ 价格涨跌当标签” 训练深度模型，从文本里挖出涨跌信号；
3. **两阶段 TSH-LSTM**：单变量 + 多变量 LSTM，用**误差倒数法**融合，兼顾短期精度和长期稳健；
4. **经济计量 + 深度学习结合**：先用逐步回归筛选因子（可解释），再喂给深度学习（高精度）。

十、局限与可复现性

1. **只在大豆期货一个品种上验证**，推广性未知；
2. **微博文本拿不到**是最大复现障碍：论文没公开语料，历史微博（尤其 2011–2015）几乎爬不到，只能发邮件向作者索取；
3. 深度学习仍是“ 黑箱” ，缺可解释性；未来方向：ITD 分解、Granger 因果检验、SHAP/LIME。